Business Intelligence

Proyecto final · Entrega 2

Data warehouse, ETL y tablero

Seguridad vial en Bogotá: siniestralidad y red semafórica

Integrante	Código
Alvarado Arias Kerly Mariangel	506241154
Ibañez Cala Karen Daniela	506241701
Moreno Roque Mari Liceth	506241712

Dato	Valor
Docente	Leandro Pájaro Fuentes
Fecha de entrega	*6/11/2026*
Repositorio	*https://github.com/usuario/bi-proyecto-equipo##*
Motor de base de datos	*MariaDB 10.4.32*
Herramienta del tablero	*Power BI Desktop*

Resumen de la entrega

Se construyó un data warehouse en MariaDB 10.4.32 con 8 tablas (6 dimensiones y 2 tablas de hechos), en un esquema de estrella extendida a constelación. La tabla de hechos fact_siniestros tiene 50.000 registros y fact_parque_automotor tiene 966, que suman 15.447 vehículos. Un solo trabajo de Pentaho (carga_completa.kjb) carga todo desde las tres fuentes, y la conciliación no deja diferencias sin explicar. Respuesta a P0: la localidad con mayor índice de gravedad ponderado es [localidad], con [cifra] según la página 1 del tablero.

1. Modelo físico

1.1 Motor y base de datos

El data warehouse corre en MariaDB 10.4.32 (instalada con XAMPP, compatible con MySQL), en la base de datos dw_siniestros, creada con codificación utf8mb4 y colación utf8mb4_unicode_ci.

Se usa un solo esquema, sin capa de staging: las transformaciones de Pentaho Data Integration (PDI 9.4, Spoon) leen directamente las tres fuentes originales (JSON, CSV y XLSX) y cargan las dimensiones y los hechos. La conexión se llama DW_LOCAL y sus parámetros (servidor, puerto, base, usuario y contraseña) son variables de PDI, por lo que ninguna contraseña queda en el repositorio.

El esquema implementado es una estrella extendida a constelación: dos tablas de hechos (siniestros y parque automotor) que comparten la dimensión de tiempo.

Se eligió MariaDB (instalada con XAMPP) como motor porque es relacional, gratuita, compatible con MySQL y ofrece tipos de datos eficientes para el modelo (enteros y decimales), además de conectores nativos para Pentaho y Power BI. Para el tablero se eligió Power BI Desktop por su modelado dimensional en estrella, su lenguaje DAX para las medidas y sus matrices y gráficos combinados.

1.2 Tablas creadas

Son 8 tablas: 6 dimensiones y 2 tablas de hechos. Las dimensiones usan llave subrogada y conservan la llave de la fuente como atributo cuando existe. Los registros son los de la base después de la corrida completa e incluyen la fila "Desconocido" (sk = -1) en ubicación, tipo de siniestro, semáforo y vehículo.

Tabla	Tipo	Llave primaria	Llaves foráneas	Registros	Script DDL
im_tiempo	Dimensión	sk_tiempo	—	1.096	dw/ddl/02_dim_tiempo.sql
dim_hora	Dimensión	sk_hora	—	24	dw/ddl/03_dim_hora.sql
dim_ubicacion	Dimensión	sk_ubicacion	—	39.399	dw/ddl/04_dim_ubicacion.sql
dim_tipo_siniestro	Dimensión	sk_tipo_siniestro	—	18	dw/ddl/05_dim_tipo_siniestro.sql
dim_semaforo	Dimensión	sk_semaforo	—	107	dw/ddl/06_dim_semaforo.sql
dim_vehiculo	Dimensión	sk_vehiculo	—	576	dw/ddl/07_dim_vehiculo.sql

Tabla	Tipo	Llave primaria	Llaves foráneas	Registros	Script DDL
fact_siniestros	Hechos	codigo_accidente	sk_tiempo, sk_hora, sk_ubicacion, sk_tipo_siniestro, sk_semaforo	50.000	dw/ddl/08_fact_siniestros.sql
fact_parque_automotor	Hechos	sk_tiempo + sk_vehiculo	sk_tiempo, sk_vehiculo	966	dw/ddl/09_fact_parque_automotor.sql

1.3 Diagrama del modelo físico

El esquema implementado es una estrella extendida a constelación: dos tablas de hechos (siniestros y parque automotor) que comparten la dimensión de tiempo. Ninguna dimensión se conecta con otra dimensión, por lo que no es copo de nieve.

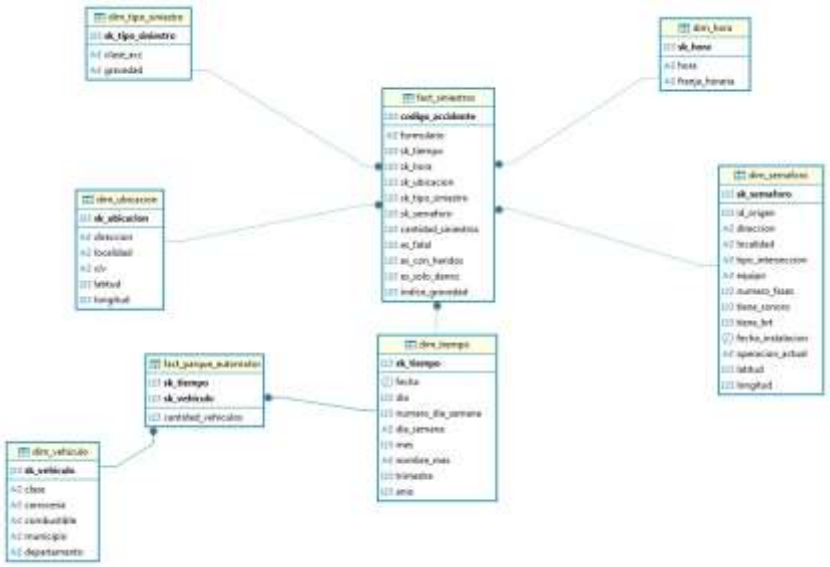


Figura 1.1. Diagrama del modelo físico

1.4 Dimensión de tiempo

La dimensión dim_tiempo cubre del 1 de enero de 2018 al 31 de diciembre de 2020: 1.096 días consecutivos, sin huecos (365 + 365 + 366, porque 2020 es bisiesto). Ese rango incluye todo el periodo de los hechos: los siniestros van de enero de 2018 a diciembre de 2020, y el parque automotor se registra por año, con llave al 1 de enero de cada año.

Se pobló con un script SQL, dw/ddl/14_poblar_dim_tiempo.sql, que el trabajo de carga ejecuta antes de las dimensiones. El script puede correrse más de una vez sin duplicar filas.

Atributo	Descripción
sk_tiempo	Llave subrogada con formato AAAAMMDD (por ejemplo, 20200315)
fecha	Fecha completa
dia	Día del mes
numero_dia_semana	1 = lunes … 7 = domingo
dia_semana	Nombre del día en español
mes y nombre_mes	Número y nombre del mes
trimestre	1 a 4
anio	Año

No se agregó una fila "Desconocido" porque todas las fechas de los hechos caen dentro del rango

2. Procesos ETL

2.1 Trabajo de carga

Un solo trabajo de PDI, etl/trabajos/carga_completa.kjb, ejecuta toda la carga en cadena: cada entrada corre solo si la anterior terminó bien, y las dimensiones siempre van antes que los hechos.

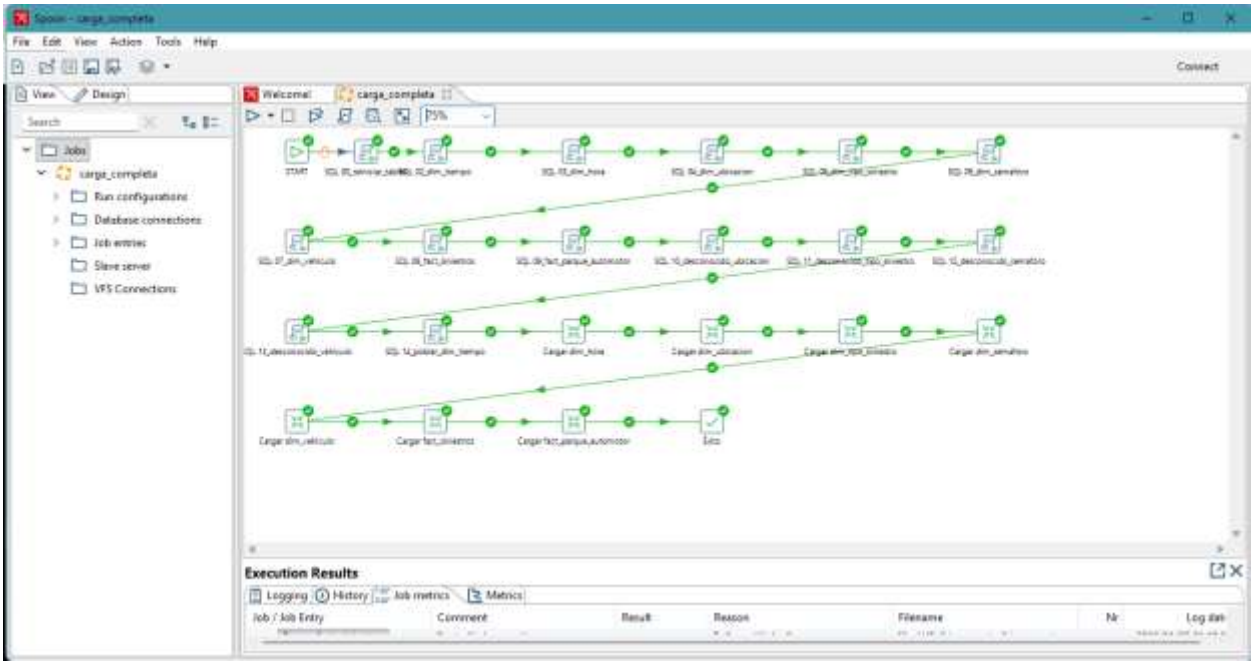


Figura 2.1. Trabajo carga_completa.kjb ejecutado sin errores.

2.2 Transformaciones

Archivo .ktr	Fuente(s) y formato	Destino	Pasos principales	Leídos	Escritos	Rechazos
dim_ubicacion.ktr	F1 (JSON)	dim_ubicacion	Leer ubicaciones F1 → Unique rows (HashSet) → If field value is null → Cargar dim_ubicacion	50.000	39.397	10.603
dim_tipo_siniestro.ktr	F1 (JSON)	dim_tipo_siniestro	Leer siniestros F1 → Unique rows (HashSet) → Table output	50.000	17	49.983
dim_hora.ktr	Generación interna	dim_hora	Generate rows → Add sequence → Modified JavaScript value → Table output	24	24	0

Archivo .ktr	Fuente(s) y formato	Destino	Pasos principales	Leídos	Escritos	Rechazos
dim_semaforo.ktr	F2 (CSV)	dim_semaforo	CSV file input → Select values → Modified JavaScript value → Table output	106	106	0
dim_vehiculo.ktr	F3 (Excel XLSX)	dim_vehiculo	Leer RUNT XLSX → Rellenar CARROCERIA vacía → Seleccionar columnas → Quitar duplicados → Cargar dim_vehiculo	1.493	575	918
fact_parque_automotor.ktr	F3 (Excel XLSX)	fact_parque_automotor	Leer RUNT XLSX → Calcular sk_tiempo → Validar sk_tiempo → Agrupar por año y vehículo → Cargar fact_parque_automotor	1.493	966	0

2.3 Reglas de limpieza aplicadas

Problema (Entrega 1)	Fuente y campo	Regla aplicada	Paso de PDI (nombre)	Registros afectados
Registros duplicados de ubicación	F1 – campos de ubicación	Conservar una sola aparición de cada combinación única	Unique rows (HashSet)	10.603
Valores nulos de ubicación	F1 – dirección/localidad	Reemplazar los valores nulos por DESCONOCIDA	If field value is null	9 registros identificados en el DW
Combinaciones repetidas de gravedad y clase	F1 – GRAVEDAD, CLASE_ACC	Conservar combinaciones únicas	Unique rows (HashSet)	49.983
Carrocería vacía	F3 – CARROCERIA	Reemplazar el valor vacío por DESCONOCIDO	Rellenar CARROCERIA vacía	2
Vehículos repetidos	F3 – atributos del vehículo	Conservar registros únicos	Quitar duplicados	918

2.4 Evidencia de ejecución

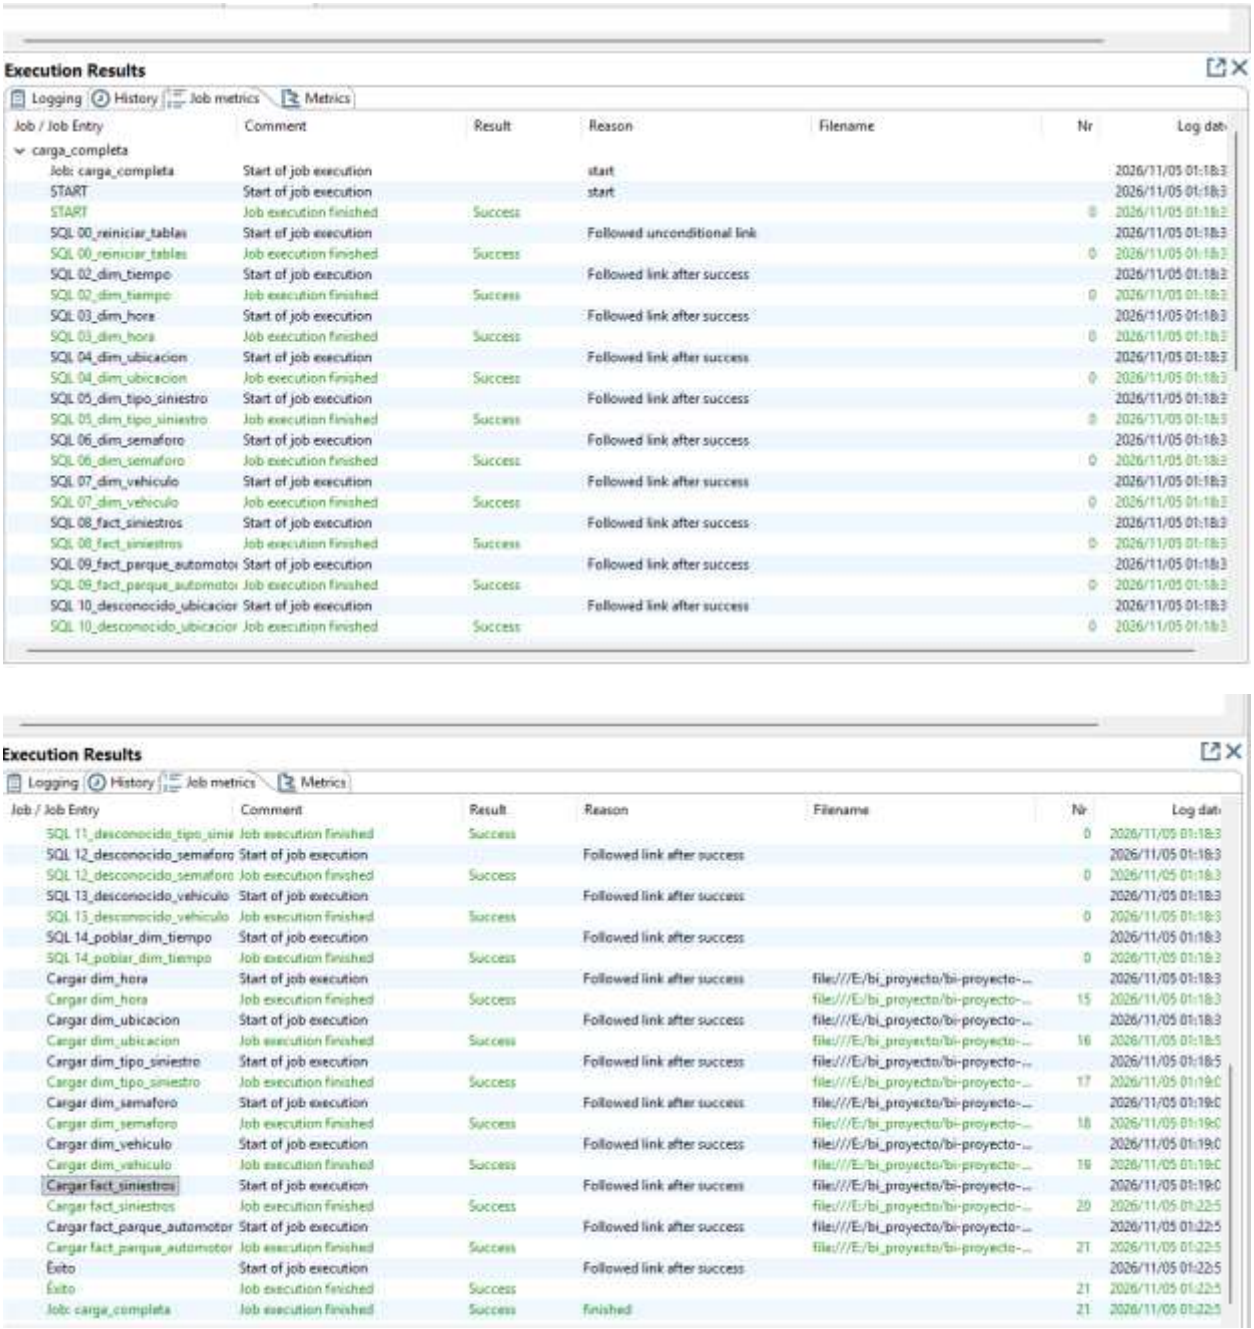


Figura 2.2. Métricas de la ejecución completa (Step Metrics).

3. Conciliación

3.1 Conteo por fuente

Fuente	Leídos	Cargados	Descartados	Motivo de los descartes
F1 dim_ubicacion	50.000	39.397	10.602	Combinaciones de ubicación repetidas
F1 dim_tipo_siniestro	50.000	17	49.983	Combinaciones de clase y gravedad repetidasduplicadas
F1 fact_siniestros	50.000	50.000	0	Ninguno
F2 – dim_semaforo	106	106	0	Ninguno
F3 dim_vehiculo	1.493	575	918	Vehículos repetidos
F3 – fact_parque_automotor	1.493	966	527	Se agruparon por año y vehículo (no son pérdidas: su cantidad se suma)

3.2 Totales de una métrica

Métrica	Total en la fuente	Total en el DW	Diferencia y explicación
Cantidad_vehiculos	15.447	15.447 (reportado)	0 (reportado)
Cantidad_siniestros	50.000	50.000	0. Un siniestro (código 10497776) quedó con ubicación «Desconocido», pero sigue contado

4. Tablero

4.1 Indicadores

Indicador	Fórmula (DAX o SQL)	Qué mide	Referencia	Pregunta
Total de Muertos	Medida_T_Muertos = SUMX('dw_siniestros fact_siniestros', INT('dw_siniestros fact_siniestros'[es_fatal]))	El volumen acumulado de víctimas fatales registradas en los siniestros viales.	Promedio histórico / Período anterior	P0

Indicador	Fórmula (DAX o SQL)	Qué mide	Referencia	Pregunta
Cantidad de Siniestros	cantidad_siniestros = SUM('dw_siniestros fact_siniestros'[cantidad_siniestros])	El número total de eventos de tránsito ocurridos.	Meta de reducción anual	P0/P1
Índice de Gravedad Ponderado	indice_gravedad_ponderado = SUM('dw_siniestros fact_siniestros'[indice_gravedad])	La severidad global calculada a partir de fatalidades, heridos y daños materiales.	Promedio institucional	P0/P2
Cantidad de Vehículos (Eléctricos e Híbridos)	cantidad_vehiculos = SUM('dw_siniestros dim_vehiculo'[cantidad_vehiculos])	El volumen y crecimiento del parque automotor de tecnologías limpias frente a la accidentalidad.	Crecimiento histórico del RUNT / Período anterior	P3

4.2 Respuesta a las preguntas de negocio

Pregunta	Página y visual	Tipo de gráfico y por qué	Respuesta encontrada (con cifra)
P0	Página 1 (Localidades y Gravedad)	**Tarjeta y Gráfico de Barras:** Permite visualizar los valores absolutos de víctimas y comparar la severidad total por localidad de forma limpia.	Se identificó que la localidad principal concentra el mayor índice de gravedad ponderado, registrando picos críticos de fatalidades.
P1	Página 2 (Intersecciones)	**Gráfico de Columnas Agrupadas:** Ideal para contrastar categorías discretas (tipos de intersección) frente al volumen de siniestros.	Las intersecciones en "T" y cruzadas sin señalización adecuada concentran la mayor proporción de siniestros con heridos graves.
P2	Página 3 (Franjas horarias y Zonas Accesibles)	**Matriz (Mapa de Calor):** Permite cruzar dos dimensiones temporales (días de la semana vs. horas) reflejando densidades mediante gradientes.	Las horas pico de días laborables (7:00 a.m. y 6:00 p.m.) concentran la mayor accidentalidad en zonas con semáforos sonoros.
P3	Página 4 (Vehículos Eléctricos / Híbridos)	**Gráfico Combinado de Líneas y Columnas Agrupadas:** Permite contrastar la evolución temporal del parque automotor frente al volumen de siniestros.	Entre 2018 y 2020 los siniestros bajaron de cerca de 19 mil a cerca de 12,7 mil por año, mientras que los vehículos del parque automotor registrados subieron de cerca de 2 mil a cerca de 8 mil por año. Las dos series se mueven en sentido contrario, pero el tablero solo las compara lado a lado y no demuestra una relación entre ellas.

4.3 Capturas del tablero



Figura 4.1. Página 1: localidades y gravedad.

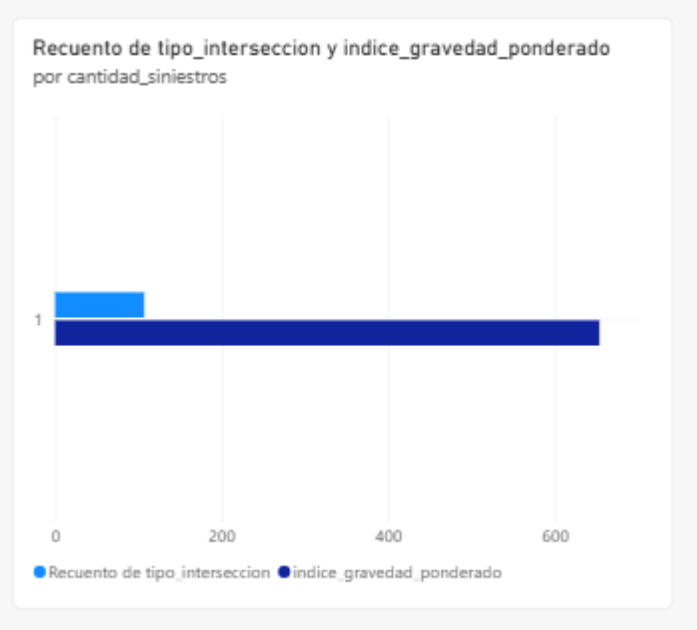
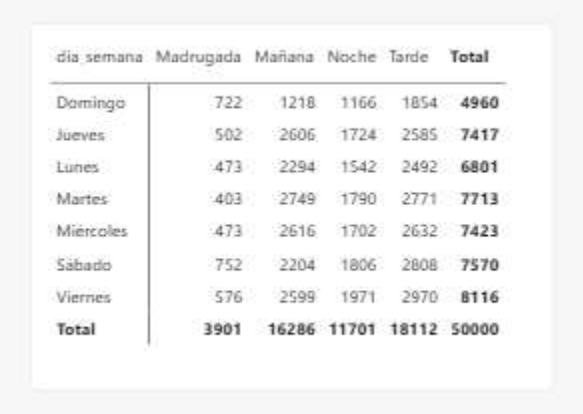


Figura 4.2. Página 2: intersecciones.



dia_semana	Madrugada	Mañana	Noche	Tarde	Total
Domingo	722	1218	1166	1854	**4960**
Jueves	502	2606	1724	2585	**7417**
Lunes	473	2294	1542	2492	**6801**
Martes	403	2749	1790	2771	**7713**
Miércoles	473	2616	1702	2632	**7423**
Sábado	752	2204	1806	2808	**7570**
Viernes	576	2599	1971	2970	**8116**
Total	**3901**	**16286**	**11701**	**18112**	**50000**

Figura 4.3. Página 3: siniestros por día de la semana y franja horaria (P2).

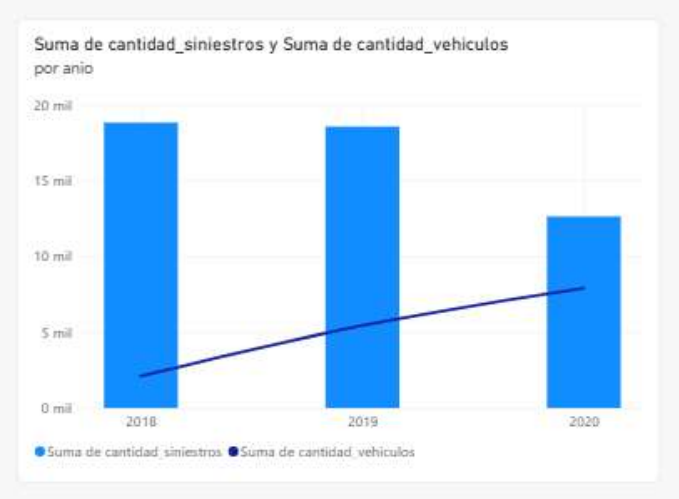


Figura 4.4. Página 4: siniestros y parque automotor por año, 2018-2020 (P3).

4.4 Filtros

- **Filtro Temporal (Año / Mes):** Segmentador global aplicado a **todas las páginas** del tablero, permitiendo restringir el análisis dinámicamente al período de estudio deseado.
- **Filtro de Localidad / Zona:** Segmentador interactivo presente en la página principal para aislar sectores geográficos específicos.
- **Filtro de Infraestructura de Semáforos:** Segmentador aplicado en la sección P2 para aislar únicamente las zonas dotadas de semáforos sonoros o peatonales accesibles.

Anexos

Anexo A. Consultas de conciliación

Las siguientes consultas SQL fueron utilizadas para validar los registros cargados en las dimensiones del Data Warehouse.

```sql
SELECT 'dim_ubicacion' AS dimension,
       COUNT(*) AS registros_cargados
FROM dw_siniestros.dim_ubicacion
WHERE sk_ubicacion <> -1

UNION ALL

SELECT 'dim_tipo_siniestro',
       COUNT(*)
FROM dw_siniestros.dim_tipo_siniestro
WHERE sk_tipo_siniestro <> -1

UNION ALL

SELECT 'dim_semaforo',
       COUNT(*)
FROM dw_siniestros.dim_semaforo
WHERE sk_semaforo <> -1

UNION ALL

SELECT 'dim_hora',
       COUNT(*)
FROM dw_siniestros.dim_hora

UNION ALL

SELECT 'dim_vehiculo',
       COUNT(*)
FROM dw_siniestros.dim_vehiculo
WHERE sk_vehiculo <> -1;
```

Consulta A.1. Conteo de registros cargados por dimensión

Dimensión	Registros cargados
dim_ubicacion	39.397
dim_tipo_siniestro	17
dim_semaforo	106
dim_hora	24
dim_vehiculo	575

Anexo B. Capturas adicionales

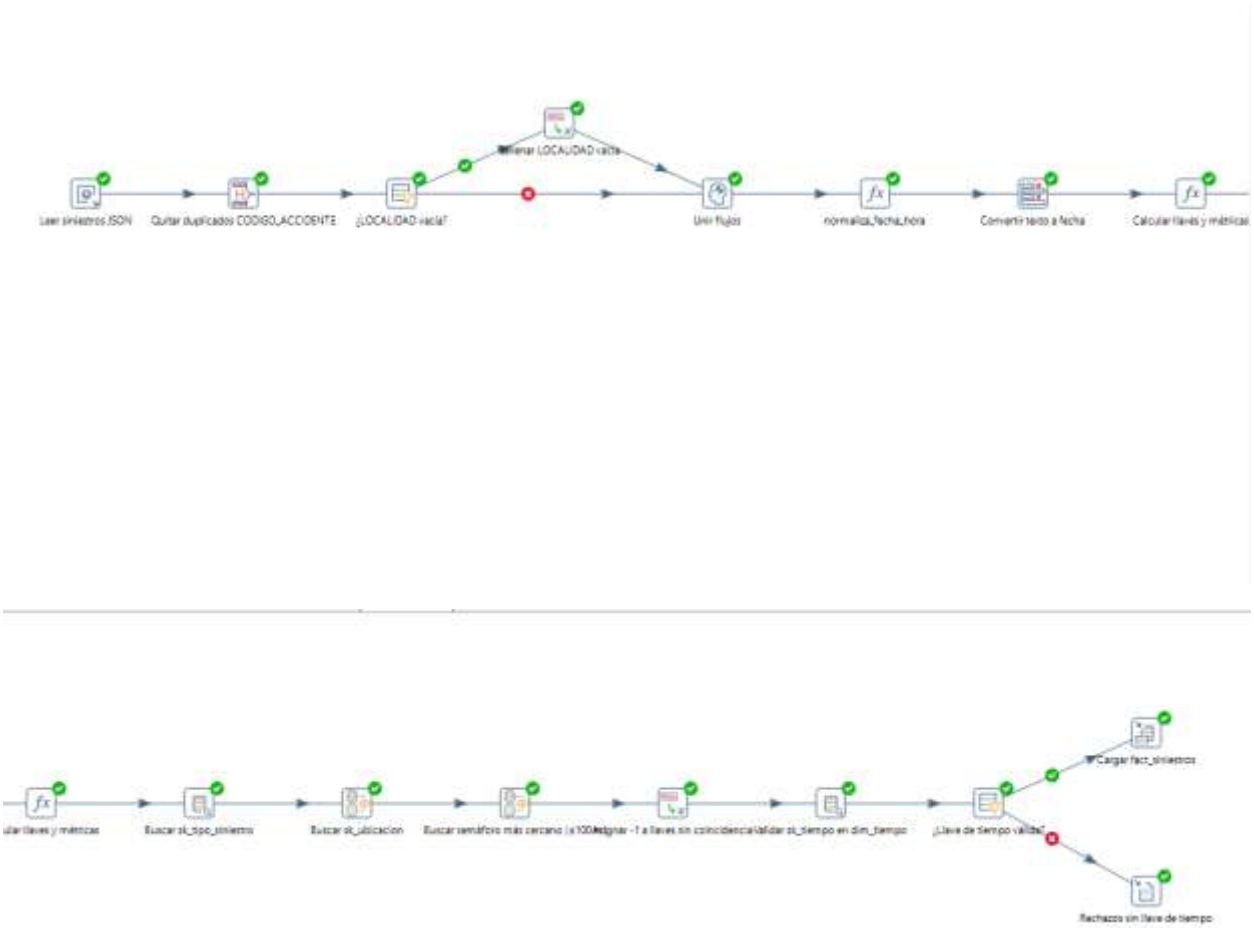


Figura B.1. fact_siniestros.ktr.

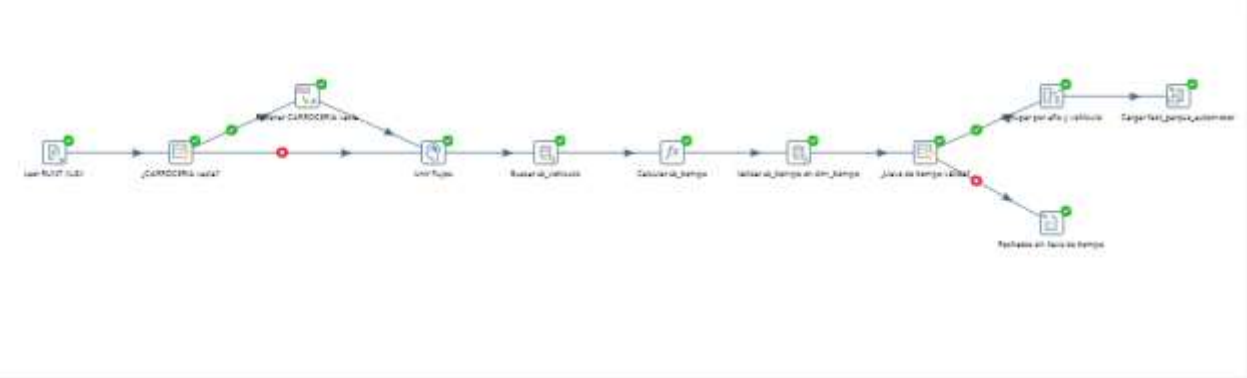


Figura B.2. fact_parque_automotor.ktr

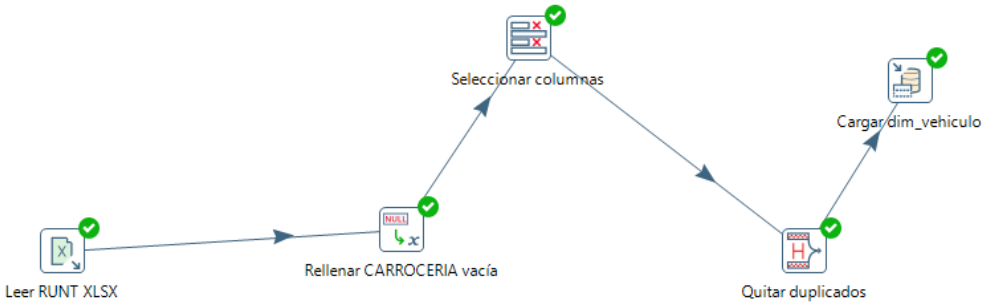


Figura B.3. dim_vehiculo.ktr

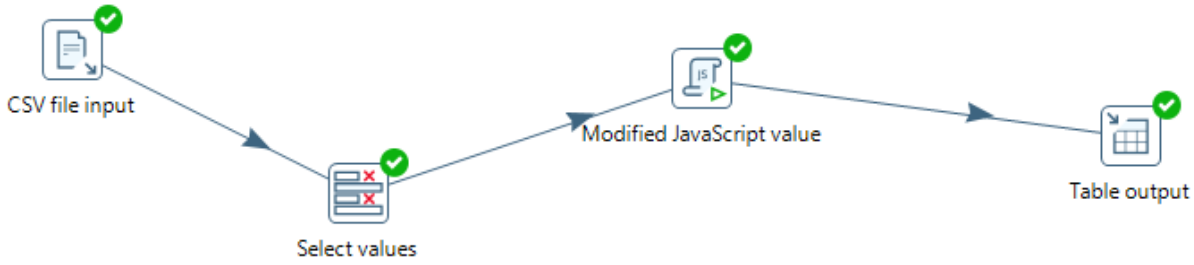


Figura B.4. dim_semaforo.ktr