Business Intelligence

Proyecto final · Entrega 3

Modelo predictivo

Seguridad vial en Bogotá: siniestralidad y red semafórica

Integrante	**Código**
Alvarado Arias Kerly Mariangel	506241154
Ibañez Cala Karen Daniela	506241701
Moreno Roque Mari Liceth	506241712

Dato	**Valor**
Docente	Leandro Pájaro Fuentes
Fecha de entrega	*13/11/2026*
Repositorio	https://github.com/Kareniba/bi-proyecto-equipo506241154
Entorno del modelo	*Python 3.x en Jupyter / Google Colab*

Resumen de la entrega

Este trabajo busca responder cuántos siniestros graves (con heridos o fallecidos) habrá en cada localidad de Bogotá el próximo mes, para decidir dónde reforzar el control y la señalización. Con datos del data warehouse de 2018 a 2020 se compararon una regresión lineal y un bosque aleatorio, y se probaron con julio a diciembre de 2020. Se eligió la regresión lineal, con un MAE de 4,11 siniestros graves por localidad y mes, por debajo del umbral de 5 fijado como criterio de éxito. Para enero de 2021 pronostica unos 475 siniestros graves en Bogotá, con Kennedy (70) como la localidad donde conviene empezar, y las predicciones quedaron en el data warehouse y en una página del tablero junto a los valores reales.

1.1 Pregunta y decisión

Pregunta BA (nueva): ¿Cuántos siniestros graves (con heridos o fallecidos) habrá en cada localidad el próximo mes, para decidir dónde reforzar control y señalización?

Por qué es una pregunta nueva: deriva de P0 (qué localidades concentran la mayor gravedad), pero mira hacia adelante. No se tomó P3 porque es descriptiva (compara el parque automotor con la siniestralidad) y el parque automotor solo tiene 3 años de datos (2018-2020), insuficientes para entrenar un modelo.

Decisión que apoya: la entidad de movilidad decide cada mes en qué localidades concentrar los recursos limitados de control en vía y señalización. Con la predicción por localidad se prioriza primero donde se esperan más siniestros graves, en lugar de repartir los recursos por igual.

1.2 Variable objetivo y tipo de problema

Elemento	Respuesta
Variable objetivo	Siniestros graves (con heridos o fallecidos) por localidad y mes
Tipo de problema	Regresión
Unidad de predicción	Una predicción por localidad y mes

1.3 Criterio de éxito

El modelo se considera exitoso si el MAE sobre el conjunto de prueba es menor a 5 siniestros graves por localidad y mes. El umbral se fijó antes de entrenar, con datos de entrenamiento: repetir el valor del mes anterior da un MAE de 6,27 en ese periodo, y 5 equivale a cerca de una cuarta parte de la mediana mensual por localidad (21 siniestros graves).

2. Comprensión de los datos

2.1 Consulta de extracción

La consulta está en modelo/extraccion.sql y se ejecuta sobre el data warehouse dw_siniestros:

```
SELECT
  l.localidad,
  m.anio,
  m.mes,
  COALESCE(a.siniestros_total, 0)  AS siniestros_total,
  COALESCE(a.siniestros_graves, 0) AS siniestros_graves,
  COALESCE(a.fatales, 0)           AS fatales
FROM (SELECT DISTINCT localidad
        FROM dw_siniestros.dim_ubicacion
       WHERE sk_ubicacion > 0) AS l
CROSS JOIN (SELECT DISTINCT anio, mes
              FROM dw_siniestros.dim_tiempo) AS m
LEFT JOIN (
  SELECT u.localidad, t.anio, t.mes,
         COUNT(*)                          AS siniestros_total,
```

```
        SUM(f.es_fatal + f.es_con_heridos) AS siniestros_graves,
        SUM(f.es_fatal)                    AS fatales
    FROM dw_siniestros.fact_siniestros f
    JOIN dw_siniestros.dim_tiempo    t ON t.sk_tiempo    = f.sk_tiempo
    JOIN dw_siniestros.dim_ubicacion u ON u.sk_ubicacion = f.sk_ubicacion
   WHERE f.sk_ubicacion > 0
   GROUP BY u.localidad, t.anio, t.mes
) AS a ON a.localidad = l.localidad AND a.anio = m.anio AND a.mes = m.mes
ORDER BY l.localidad, m.anio, m.mes;
```

Qué une: la tabla de hechos fact_siniestros con dim_tiempo (por sk_tiempo, para obtener año y mes) y con dim_ubicacion (por sk_ubicacion, para obtener la localidad), y cuenta los siniestros por localidad y mes. Ese resultado se une con el producto cruzado de todas las localidades y todos los meses (CROSS JOIN y LEFT JOIN), de modo que existe una fila por cada combinación localidad-mes, incluso las que no tuvieron siniestros; en esas filas COALESCE pone 0.

Qué calcula: siniestros_total (siniestros del mes en la localidad), siniestros_graves (suma de es_fatal y es_con_heridos; es la variable objetivo) y fatales (siniestros con fallecidos).

Qué filtra: sk_ubicacion > 0, para excluir la fila «Desconocido» de la dimensión de ubicación (el siniestro 10497776). El resultado tiene 756 filas: 21 localidades × 36 meses, de enero de 2018 a diciembre de 2020.

2.2 Descripción del conjunto de datos

El conjunto extraído tiene 756 registros, uno por localidad y mes (21 localidades × 36 meses), de enero de 2018 a diciembre de 2020. Tras la limpieza quedan 660 registros para modelar.

Variable	Tipo	Papel	Origen (tabla.columna)	Descripción
localidad	Categórica	Predictora	dim_ubicacion.localidad	Localidad de Bogotá
anio	Numérica (entero)	No usada como predictora (solo ordena y divide en el tiempo)	`dim_tiempo.anio`	Año del registro (2018 a 2020)
mes	Numérica (entero)	Predictora	`dim_tiempo.mes`	Mes del año (1 a 12)
siniestros_total	Numérica (entero)	Solo como valor del mes anterior (`total_mes_anterior`)	COUNT(*) de fact_siniestros	Total de siniestros de la localidad en el mes
fatales	Numérica (entero)	No usada	`SUM(fact_siniestros.es_fatal)`	Siniestros con fallecidos en el mes
siniestros_graves	Numérica (entero)	Objetivo	`SUM(fact_siniestros.es_fatal + es_con_heridos)`	Siniestros con heridos o fallecidos en la localidad y el mes

2.3 Distribución de la variable objetivo

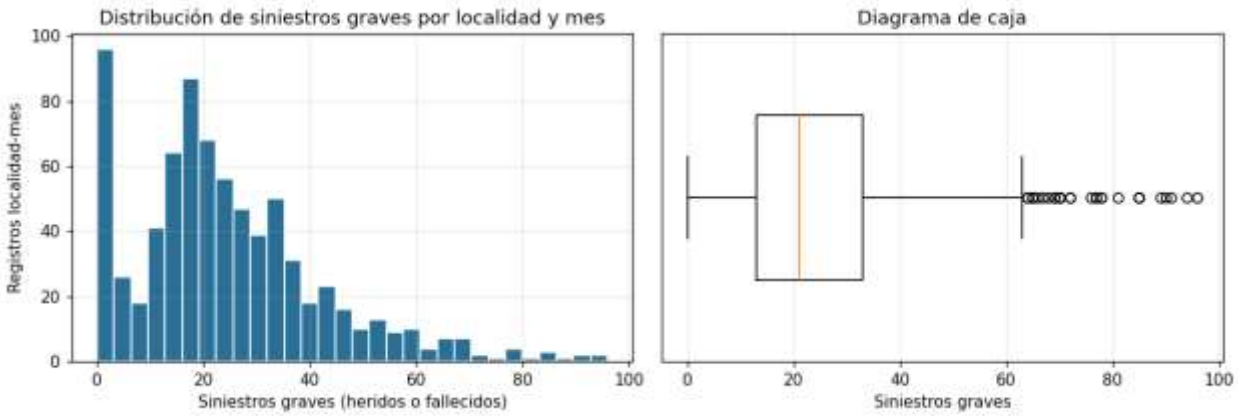


Figura 2.1. Distribución y diagrama de caja de los siniestros graves por localidad y mes.

El histograma evidencia un marcado sesgo positivo en la distribución, donde la mayor parte de las localidades registran frecuencias mensuales bajas o moderadas de siniestros graves. Por su parte, el diagrama de caja corrobora la presencia de valores atípicos superiores a los 63 incidentes

mensuales, los cuales corresponden a zonas de alta afluencia vehicular en la ciudad y no a errores de captura.

2.4 Análisis exploratorio



Figura 2.2. Evolución mensual de los siniestros graves en Bogotá y el impacto del confinamiento.

Este gráfico muestra la tendencia temporal global de la siniestralidad vial en Bogotá a lo largo de los 36 meses analizados. Se destaca una caída drástica y abrupta durante los meses de aislamiento estricto de 2020, seguida de una gradual recuperación conforme se reactivó la movilidad urbana.

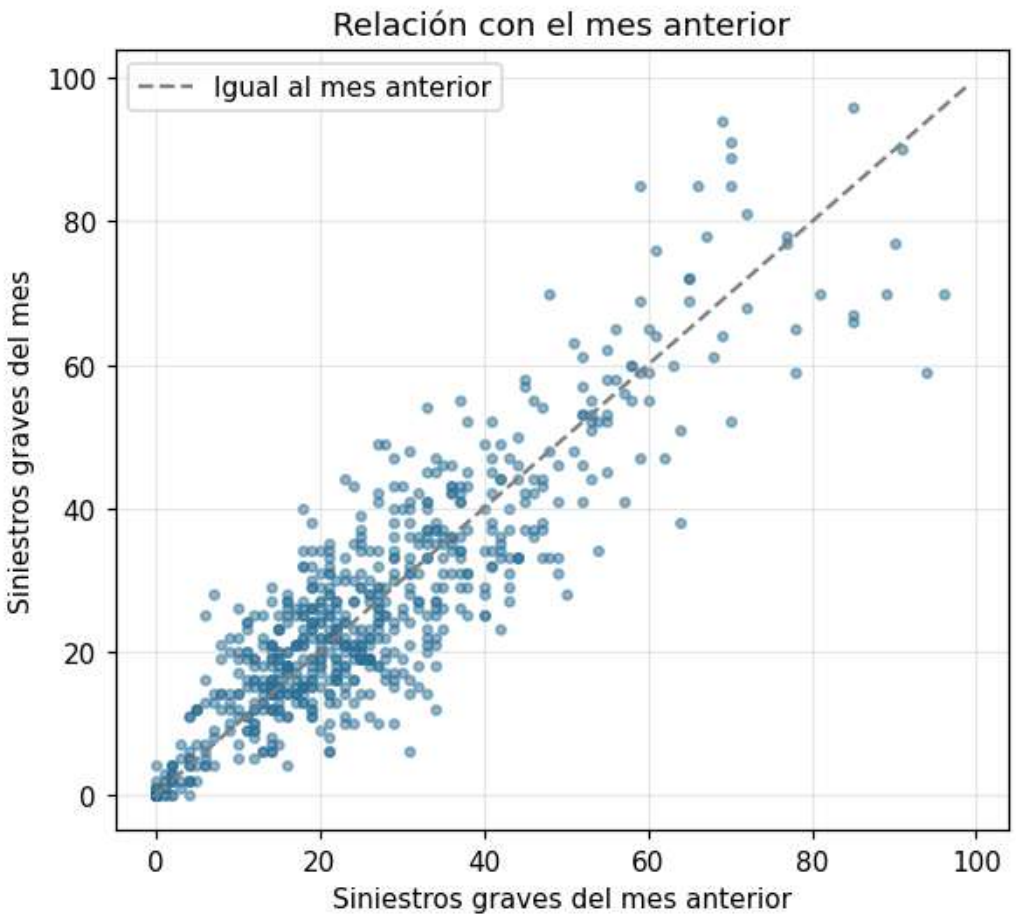


Figura 2.3. Relación y correlación lineal entre la siniestralidad del mes actual y el mes anterior.

La dispersión confirma una fuerte correlación directa entre el volumen de siniestros graves de un mes con respecto al periodo inmediatamente anterior. Esta relación lineal estrecha justifica la

incorporación de variables rezagadas como predictoras claves dentro de la arquitectura del modelo de machine learning.

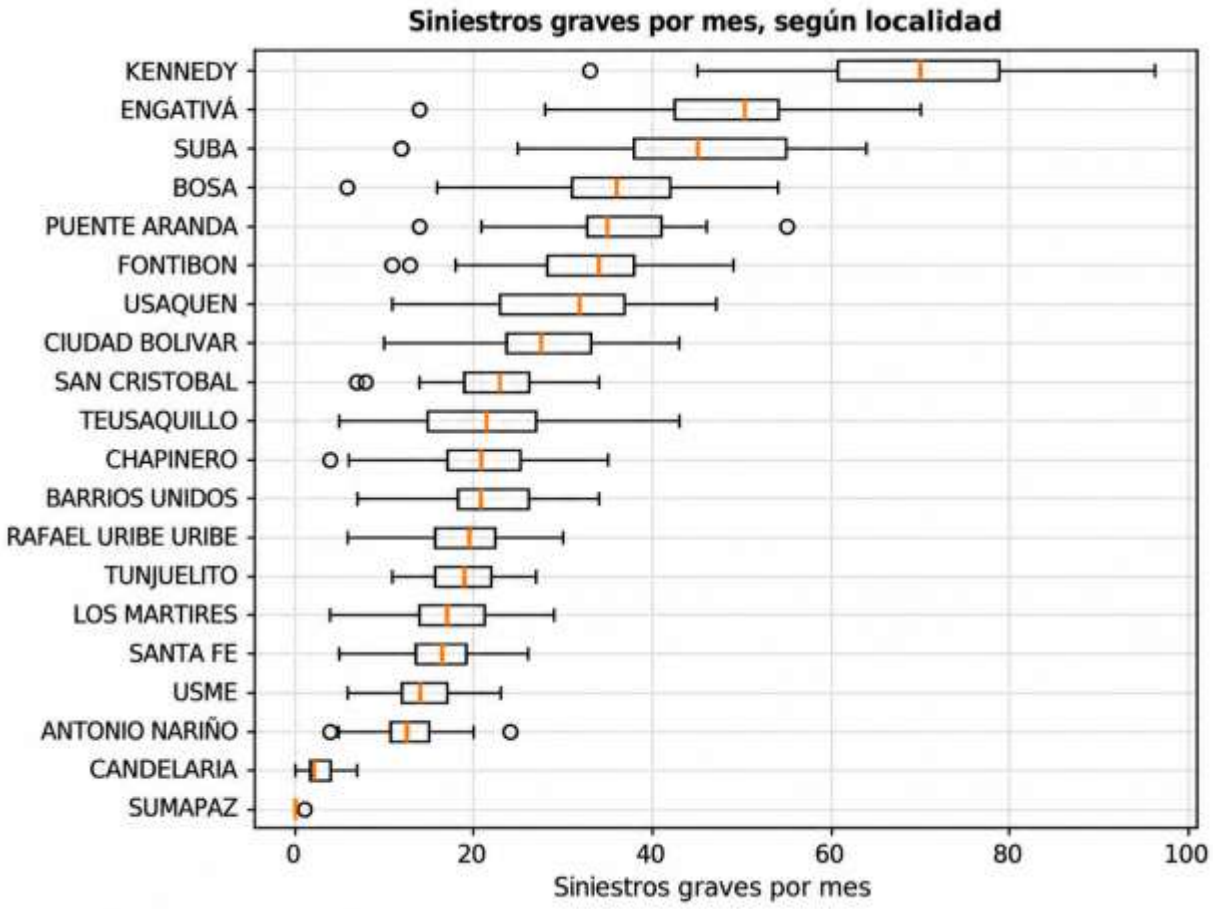


Figura 2.4. Distribución mensual de los siniestros graves según la localidad.

El gráfico compara, con diagramas de caja los siniestros graves mensuales de cada localidad. Kennedy tiene la mediana más alta (70 al mes), seguida de Engativá (50,5), Suba (45), Bosa (36) y Puente Aranda (35), mientras que Candelaria (2) y Sumapaz (0) casi no registran. Las diferencias entre localidades son grandes, por lo que la localidad se incorpora como variable predictora del modelo.

3. Preparación de los datos

3.1 Limpieza y transformación

Tratamiento	Variable(s)	Qué se hizo	Registros afectados
Nulos	Todas	No hay nulos: la consulta de extracción rellena con 0 los meses sin siniestros	0
Categoría no válida	localidad	Se excluyó la categoría «DESCONOCIDA» (36 meses, 4 siniestros graves en total), porque no es una localidad donde se pueda reforzar control	36

Tratamiento	Variable(s)	Qué se hizo	Registros afectados
Atípicos	siniestros_graves	Se conservan: los 30 valores por encima de 63 (Q3 + 1,5 × IQR) son de localidades grandes como Kennedy, Engativá y Suba, no errores de captura	30
Valores sin historia	Variables derivadas	Se eliminaron los 3 primeros meses de cada localidad (enero a marzo de 2018), que no tienen meses previos	60
Codificación categórica	localidad	One-hot encoding (una columna de 0 y 1 por localidad), con handle_unknown='ignore'	—

De 756 registros extraídos quedan 660 para modelar (20 localidades × 33 meses).

3.2 Variables derivadas

Las tres variables se calculan solo con meses anteriores al que se predice, por eso se conocen en el momento de la predicción. Además entra «mes» (1 a 12), que se conoce de antemano.

Variable nueva	Cómo se calcula	Por qué puede ayudar	¿Se conoce antes del hecho?
graves_mes_anterior	Siniestros graves de la misma localidad en el mes t−1	El nivel reciente anticipa el siguiente (correlación de 0,89 con el valor del mes)	Sí
graves_prom_3m	Promedio de siniestros graves de la localidad en t−1, t−2 y t−3	Suaviza los saltos de un solo mes (correlación de 0,92 con el valor del mes)	Sí
total_mes_anterior	Siniestros totales de la localidad en el mes t−1	La actividad vial general de la localidad arrastra los siniestros graves	Sí

3.3 División en entrenamiento y prueba

Conjunto	Registros	Periodo o proporción
Entrenamiento	540	Abril 2018 – junio 2020
Prueba	120	Julio – diciembre 2020

La división es temporal: el modelo se entrena con el pasado y se prueba con los 6 meses más recientes (20 localidades × 6 meses).

4. Modelado

4.1 Algoritmos

Los dos algoritmos se entrenaron con el mismo conjunto de entrenamiento (540 registros) y las mismas variables de entrada: localidad (codificada), mes, graves_mes_anterior, graves_prom_3m y total_mes_anterior.

Algoritmo	Por qué se eligió	Parámetros usados
Regresión lineal	Modelo base y fácil de explicar: cada variable aporta de forma proporcional y sus coeficientes se pueden leer. Sirve de referencia contra la que debe ganar un modelo más complejo	Valores por defecto de scikit-learn
Bosque aleatorio	Captura relaciones no lineales y diferencias entre localidades sin suponer una forma fija, y es poco sensible a valores extremos	n_estimators=200, max_depth=8, random_state=42

5. Evaluación

5.1 Métricas sobre el conjunto de prueba

Regresión

Algoritmo	MAE	RMSE	Interpretación en unidades del caso
Regresión lineal	4,11	5,45	En promedio se equivoca 4,1 siniestros graves por localidad y mes, frente a un promedio real de 22,6 (alrededor del 18 %). El RMSE de 5,45 es mayor que el MAE porque algunos meses tienen errores grandes: 8 de las 120 predicciones se desvían más de 10 siniestros y el mayor error fue de 15,7 (Suba, septiembre de 2020)
Bosque aleatorio	4,80	6,70	En promedio se equivoca 4,8 siniestros graves por localidad y mes; el RMSE de 6,70 indica errores grandes algo más frecuentes que en la regresión lineal

Como referencia, repetir el valor del mes anterior (sin modelo) da un MAE de 5,33 y un RMSE de 7,41 sobre la misma prueba. Con la regresión lineal, 75 de las 120 predicciones (62,5 %) quedan a 5 siniestros o menos del valor real.

Por mes, el error de la regresión lineal sobre el total de Bogotá fue pequeño en julio (+4) y agosto (−6), pero subestimó septiembre (−54) y octubre (−82), y sobreestimó noviembre (+50) y, en menor medida, diciembre (+12); el signo es predicho menos real. Las localidades con mayor error medio fueron Bosa (8,3), Engativá (7,6) y Ciudad Bolívar (7,3).

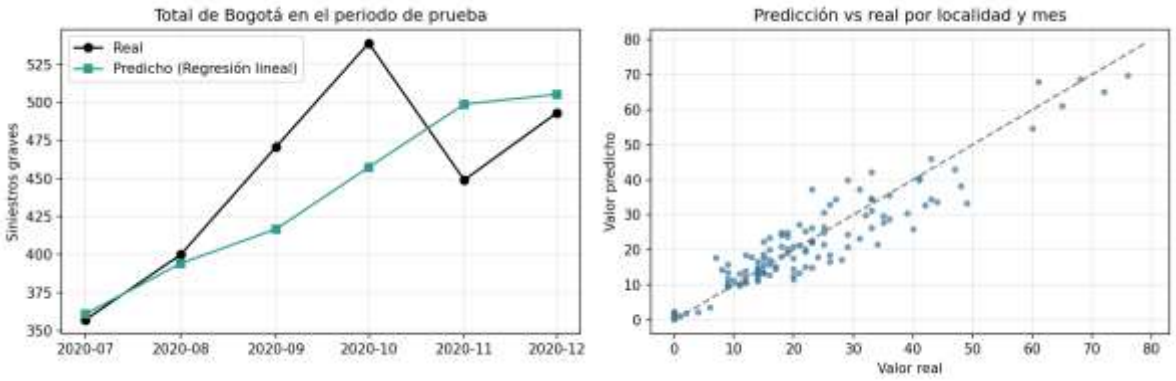


Figura 5.1. Total mensual y predicción por localidad, julio–diciembre de 2020

5.2 Comparación y elección

Se elige la **regresión lineal**: su MAE es 0,69 siniestros menor (4,11 frente a 4,80) y su RMSE es 1,25 menor (5,45 frente a 6,70) que los del bosque aleatorio, sobre los mismos 120 registros de prueba. Además es más fácil de explicar al gerente.

Prueba de robustez: si se entrena solo con 2018-2019 y se prueba con todo 2020 (confinamiento incluido), la regresión lineal empeora a un MAE de 8,63 y el bosque aleatorio a 6,14. Es decir, ante un cambio brusco como el confinamiento el bosque se deteriora menos. La elección se mantiene porque la prueba y el criterio se definieron de antemano sobre los últimos 6 meses, pero el límite queda dicho: ningún modelo entrenado antes de marzo de 2020 anticipaba la caída del confinamiento.

5.3 Variables más importantes

Importancia por permutación sobre el conjunto de prueba: cuánto aumenta el MAE, en siniestros graves, si se desordena cada variable.

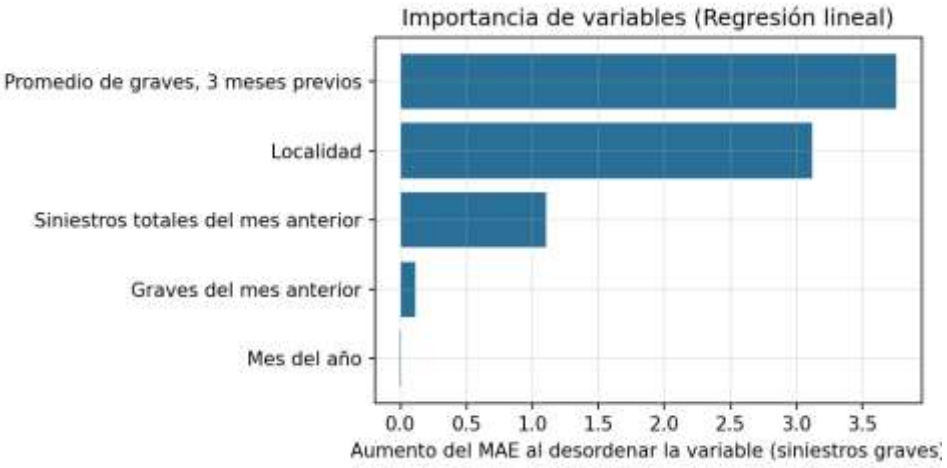


Figura 5.2. Importancia de las variables en la regresión lineal

Lo que más pesa es el nivel reciente de siniestros graves de la localidad (promedio de tres meses, con un aumento de 3,76 en el MAE) y cuál localidad es (3,12): Kennedy tiene en promedio unos 70 siniestros graves al mes y Candelaria unos 3. Los siniestros totales del mes anterior aportan 1,10, el mes anterior solo 0,11, y el mes del año casi nada, es decir, en estos datos la estacionalidad es débil. En los coeficientes de la regresión, cada siniestro grave adicional en el promedio de los tres meses previos suma 0,45 al valor predicho.

5.4 Criterio de éxito

Criterio (sección 1.3)	Valor obtenido	¿Se alcanzó?
MAE menor a 5 siniestros graves por localidad y mes	MAE = 4,11 (regresión lineal)	Sí

5.5 Respuesta a la pregunta de negocio

Con la regresión lineal reentrenada con los 36 meses de 2018-2020 y usando lo ocurrido entre octubre y diciembre de 2020, Bogotá tendría alrededor de **475 siniestros graves en enero de 2021** (493 en diciembre de 2020). Las cinco localidades con más siniestros graves esperados son:

Localidad	Siniestros graves esperados, enero 2021
Kennedy	70
Suba	42
Engativá	42
Puente Aranda	37
Bosa	35

Esas cinco concentran el 47 % del total esperado. **Decisión que apoya:** empezar el refuerzo de control y señalización de enero por Kennedy (casi 1 de cada 7 siniestros graves de la ciudad) y seguir con Suba, Engativá, Puente Aranda y Bosa. Cada cifra tiene un margen de error de unos 4 siniestros (MAE), así que las diferencias de 1 o 2 siniestros entre localidades vecinas no justifican cambiar el orden. En Bosa conviene ser prudente: el modelo predice 35 cuando en diciembre hubo 44, y es la localidad con mayor error medio en la prueba. El listado completo de las 20 localidades está en modelo/pronostico_2021_01.csv.

6. Despliegue

6.1 Tabla de predicciones

Tabla dw_siniestros.pred_siniestros_graves, con 120 registros (20 localidades × 6 meses de prueba, de julio a diciembre de 2020). El script que la crea es dw/ddl/15_pred_siniestros_graves.sql y el que la carga es dw/ddl/16_cargar_pred_siniestros_graves.sql.

Columna	Tipo	Descripción
sk_tiempo	INT (llave primaria, parte 1)	Llave a dim_tiempo: primer día del mes, formato AAAAMMDD
localidad	VARCHAR(60) (llave primaria, parte 2)	Localidad; coincide con dim_ubicacion.localidad
valor_real	INT	Siniestros graves observados en el mes
valor_predicho	DECIMAL(8,2)	Siniestros graves predichos por el modelo elegido
modelo	VARCHAR(40)	Algoritmo que generó la predicción (Regresión lineal)

La unión con la dimensión de tiempo es por sk_tiempo. La unión con ubicación es por localidad, que en dim_ubicacion es un atributo con muchas direcciones por localidad, no una llave única.

6.2 Página de predicciones en el tablero

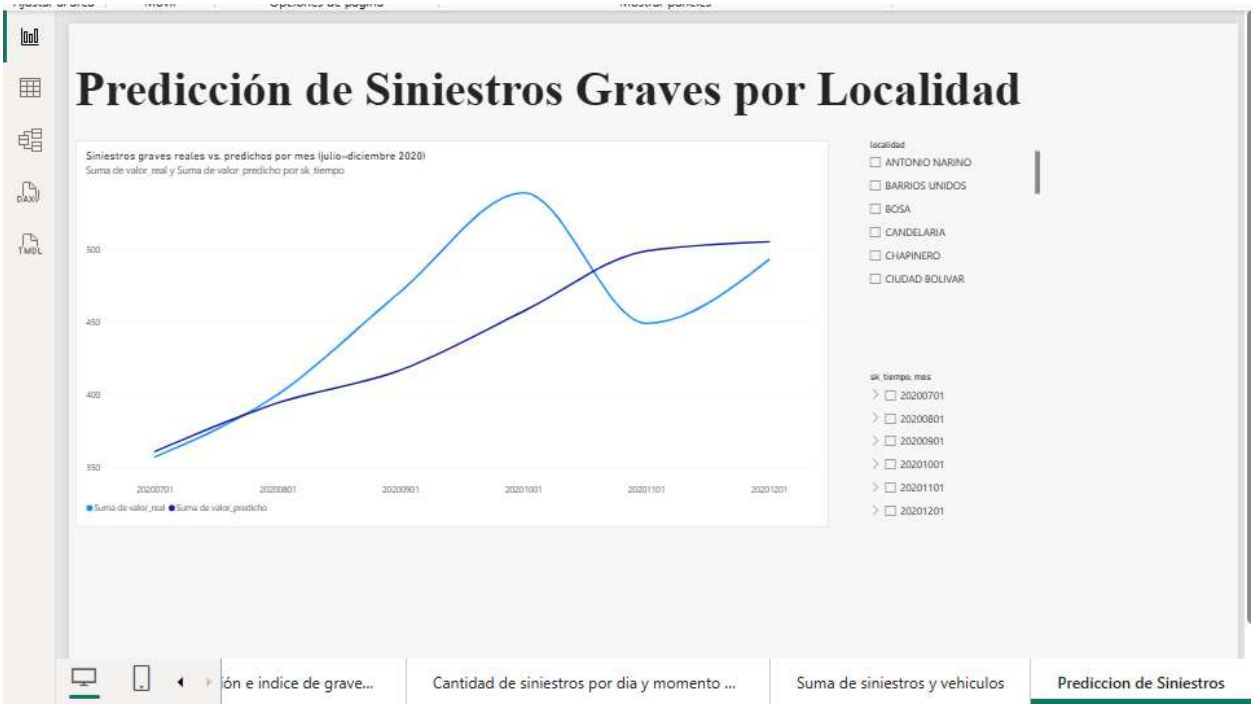


Figura 6.1. Página de predicciones del tablero: siniestros graves reales y predichos por mes

El gráfico compara la evolución mensual de los siniestros graves reales frente a los predichos por el modelo durante el periodo de prueba. Además, incorpora filtros interactivos por localidad y mes (sk_tiempo) para analizar el desempeño de las estimaciones en cada zona de la ciudad.