Business Intelligence

Proyecto final · Entrega 1

Diagnóstico, estrategia y diseño

Seguridad vial en Bogotá: siniestralidad y red semafórica

Integrante	Código
Alvarado Arias Kerly Mariangel	506241154
Ibañez Cala Karen Daniela	506241701
Moreno Roque Mari Liceth	506241712

Dato	Valor
Docente	Leandro Pájaro Fuentes
Fecha de entrega	*23/10/2026*
Repositorio	*https://github.com/Kareniba/bi-proyecto-equipo506241154*

Resumen de la entrega

El presente proyecto desarrolla una solución integral de Business Intelligence para la Secretaría Distrital de Movilidad (SDM) de Bogotá D.C., orientada a resolver la alta siniestralidad vial (1.363 siniestros con muertos y 31.527 con heridos en 2018–2020) y optimizar el funcionamiento de la red semafórica frente al crecimiento de la electromovilidad (15.447 vehículos en RUNT). La organización se diagnostica actualmente en la Fase 2 (Datos accesibles sin BI) del modelo BIMM y tiene como meta alcanzar la Fase 5 (Crecimiento del Data Warehouse y Reporting Formal). El modelo dimensional diseñado adopta una granularidad donde cada fila de la tabla de hechos representa un evento individual de siniestro vial registrado en una ubicación geográfica (coordenadas X,Y y localidad) y en una fecha y hora específicas en Bogotá D.C.

1. Caso de negocio

▸ Descripción del caso entre una y dos páginas.

1.1 Organización y contexto

La Secretaría Distrital de Movilidad (SDM) es la entidad del sector central de Bogotá D.C. encargada de formular, orientar, coordinar y ejecutar las políticas públicas de transporte, tránsito e infraestructura vial en el Distrito Capital. Como autoridad única de tránsito en una metrópoli de más de 7,8 millones de habitantes, la SDM coordina la circulación vehicular, peatonal y de transporte masivo a lo largo de 20 localidades urbanas y rurales, administrando una malla vial altamente compleja que conecta más de 1,2 millones de desplazamientos diarios.

En términos operacionales, la SDM supervisa la gestión de la red semafórica de la ciudad, compuesta por intersecciones dotadas de tecnologías heterogéneas (controladores C900, señales sonoras para invidentes, fases adaptativas y detectores por demanda). Al mismo tiempo, la entidad lidera la estrategia institucional de “Visión Cero”, una política de seguridad vial cuyo principio ético fundamental establece que ninguna muerte ni lesión grave en el tránsito es aceptable. Sin embargo, para cumplir este mandato, la SDM debe procesar e integrar volúmenes masivos de datos provenientes del historial de accidentes de tránsito, inventarios de infraestructura física y registros del parque automotor nacional.

El decisor principal en este escenario es la Subsecretaría de Gestión de la Movilidad conjuntamente con la Dirección de Seguridad Vial. La decisión estratégica y operacional que hoy no pueden tomar radica en: No es posible determinar de forma dinámica y focalizada qué intersecciones semafóricas requieren reprogramaciones urgentes de fases, instalación de dispositivos peatonales/sonoros o priorización de mantenimiento preventivo a partir de la concentración geoespacial de siniestros graves (fallecidos y heridos) y de la circulación creciente de tecnologías de bajas emisiones (vehículos híbridos y eléctricos). Actualmente, las decisiones se toman de forma reactiva o mediante análisis estáticos en hojas de cálculo aisladas, lo que impide priorizar inversiones públicas en los puntos de mayor riesgo crítico (puntos negros) de la ciudad.

1.2 Síntomas de arquitectura accidental

El funcionamiento actual del ecosistema de datos de la SDM refleja una típica arquitectura accidental, donde los sistemas han crecido de forma orgánica, fragmentada y sin una planificación analítica centralizada. A partir del análisis exhaustivo del consolidado histórico 2018–2020 (88.804 siniestros, 106 equipos semafóricos y 15.447 registros RUNT), se documentan con evidencia concreta los siguientes tres síntomas principales:

#	Síntoma	Evidencia en el caso	Capa afectada
S1	Inconsistencia de formatos, dispersión en silos y falta de	La información de siniestros se genera en archivos CSV	Fuentes de datos / Procesos ETLs

#	Síntoma	Evidencia en el caso	Capa afectada
	integración interinstitucional	georreferenciados (coordenadas X, Y), la infraestructura semafórica se administra en inventarios de equipos (CSV/XLSX) con codificaciones propietarias (C900, BT-TA) y los datos de vehículos eléctricos provienen del RUNT nacional. No existe una clave foránea o modelo común que conecte la infraestructura con los accidentes.	
S2	Deficiencias severas en la calidad del dato, marcas de tiempo heterogéneas e incompletitud espacial	El archivo de siniestros presenta valores vacíos en PK_CALZADA (18,88 %, 16.765 de 88.804 registros) y en CIV (0,33 %). Además, las dos columnas de fecha llegan como texto con sufijo de zona horaria +00 (por ejemplo, 2020/11/19 02:05:00+00) y FECHA_OCURRENCIA_ACC repite la fecha de FECHA_HORA_ACC con la hora en 00:00:00, por lo que hay que limpiar el formato y derivar la franja horaria solo de FECHA_HORA_ACC. En la red semafórica, GRUPOS_BRT está vacío en 103 de 106 registros (97,17 %) y GRUPOSSONOROS en 26 (24,53 %).	Procesos ETLs / Almacenamiento de datos.
S3	Incapacidad de analítica cruzada e inaccesibilidad para la toma de decisiones sobre electromovilidad	A pesar de que el RUNT reporta un incremento significativo en vehículos limpios (15.447 unidades entre eléctricos, híbridos a gasolina y diésel), la SDM no puede realizar cruces analíticos entre estos flujos de tráfico y la capacidad tecnológica de los semáforos (fases por demanda o activación sonara en localidades como Suba, Bosa o Engativá). Los reportes son estáticos y carecen de métricas de severidad ponderadas.	Almacenamiento de datos / Acceso usuario final.

1.3 Preguntas de negocio

Con el objetivo de transformar los datos operativos en decisiones estratégicas de movilidad y seguridad vial, se han formulado una pregunta principal (P0) y tres preguntas secundarias (P1, P2, P3), diseñadas para ser respondidas cabalmente mediante el modelo dimensional alimentado por los datos del inventario:

#	Pregunta	Tipo (BI, BA o Big Data)	Por qué es de ese tipo
P0	¿Cuáles son las localidades y corredores viales que registran mayor	BI	Describe lo ocurrido utilizando agregaciones de datos históricos

#	Pregunta	Tipo (BI, BA o Big Data)	Por qué es de ese tipo
	concentración de siniestros graves (fallecidos y heridos) por año y mes en Bogotá D.C.?		estructurados de la SDM para identificar puntos negros.
P1	¿Qué tipo de intersección semafórica (Vehicular, Peatonal, Ciclista, BRT) presenta la mayor tasa de siniestralidad grave en su área de influencia?	BI	Analiza la relación histórica entre el equipamiento e infraestructura semafórica y la severidad de los siniestros.
P2	¿En qué franjas horarias y días de la semana se concentran los siniestros por choque o atropello en zonas dotadas de semáforos sonoros o peatonales?	BI	Agrega eventos de accidentalidad cruzando las dimensiones de tiempo, tipo de accidente y características tecnológicas del semáforo.
P3	¿Cómo ha evolucionado la adopción de vehículos eléctricos e híbridos (por clase y carrocería) frente al volumen total de siniestros viales registrados en la ciudad?	BA	Evalúa tendencias, correlaciones y patrones del parque automotor limpio en relación con la dinámica general de siniestralidad vial.

2. Inventario de fuentes

Fuente	Procedencia (URL)	Formato	Registros	Periodo	Fecha de descarga	Licencia
F1	datosabiertos.bogota.gov.co (Siniestros)	CSV	88.804	2018–2020	15/10/2026	Abierta (CC BY 4.0)
F2	datosabiertos.bogota.gov.co (Red Semafórica)	CSV / XLSX	106	2018–2020	15/10/2026	Abierta (CC BY 4.0)
F3	runt.gov.co / Datos Abiertos (RUNT)	CSV / XLSX	1.493	2018–2020	15/10/2026	Pública Institucional

2.2 Problemas de calidad detectados

▸ *Mínimo un problema por fuente, con un ejemplo real tomado de los datos.*

Fuente	Campo	Problema	Ejemplo real del dato
F1	PK_CALZADA / CIV	Campos vacíos que impiden ubicar el siniestro en la malla vial.	PK_CALZADA vacío en 16.765 de 88.804 registros (18,88 %); CIV vacío en 293 (0,33 %).

Fuente	Campo	Problema	Ejemplo real del dato
F2	GRUPOS_BRT	Incompletitud en datos de soporte tecnológico específico.	GRUPOS_BRT vacío en 103 de 106 registros (97,17 %).
F3	CARROCERIA	Valor vacío en un campo categórico necesario para agrupar el parque automotor.	CARROCERIA vacío en 1 de 1.493 registros (0,07 %).

► *Los diccionarios completos van en el Anexo A y en /datos/diccionarios; la muestra de 20 filas por fuente, en /datos/muestras del repositorio.*

3. Diagnóstico de madurez

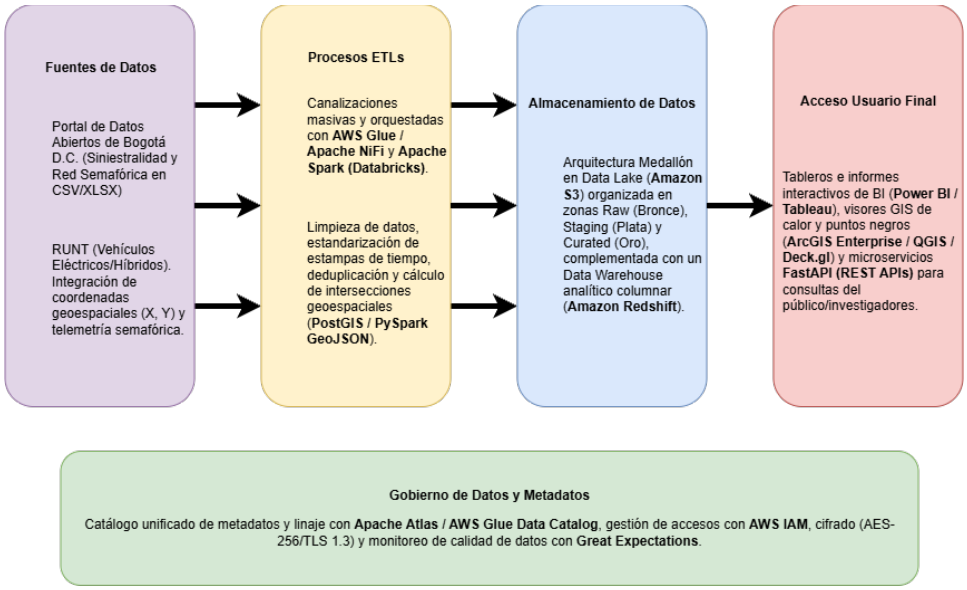
► *1 página. Use el BIMM de siete fases visto en clase (https://virtual.konradlorenz.edu.co/course/section.php?id=107056):*

- *1. No existe BI · 2. Datos accesibles sin BI · 3. Procesos formales de decisión basados en datos · 4. Data warehouse · 5. Crecimiento del DW y reporting formal · 6. Despliegue de OLAP · 7. BI formalizado*

Elemento	Respuesta
Fase actual	Fase 2. Datos accesibles sin BI
Evidencia	Sustentada en S1 (silos de información entre CSVs aislados), S2 (inconsistencias de calidad sin repositorios consolidados) y S3 (incapacidad de cruce analítico en un Data Warehouse).
Por qué no es la fase siguiente	A la SDM le falta establecer un proceso formal institucional de toma de decisiones basado en repositorios unificados, careciendo actualmente de un Data Warehouse y de pipelines ETL automatizados.
Fase objetivo al final del proyecto	Fase 5. Crecimiento del DW y reporting formal
Brechas que cierra el proyecto	1. Construcción e integración de un Data Warehouse dimensional (capa 3 de la tabla 4.2: PostgreSQL / Amazon S3). 2. Automatización de flujos ETL con control de calidad (capa 2 de la tabla 4.2: Python / AWS Glue). 3. Tableros de control y reporting formal (capa 4 de la tabla 4.2: Power BI Desktop & Service). 4. Gobierno de datos y metadatos (capa 5 de la tabla 4.2: Apache Atlas / Great Expectations / AWS IAM).

4. Arquitectura

4.1 Diagrama de cinco capas del caso



4.2 Componentes por capa

Capa	Componentes y herramientas del caso	Función en el caso
1. Fuentes de datos	*F1 (Siniestros CSV), F2 (Red Semafórica CSV/XLSX), F3 (RUNT CSV/XLSX)*	Proveen los datos brutos operacionales, geográficos y de registro vehicular de Bogotá D.C.
2. Integración (ETL)	Python (Pandas/PySpark) / AWS Glue	Extraen, limpian, estandarizan fechas/coordenadas X,Y, transforman y cargan los datos en el almacén.
3. Almacén de datos	Amazon S3 (Data Lake) / PostgreSQL (Data Warehouse dimensional)	Almacenan los datos en capas Raw/Staging y alojan las tablas de hechos y dimensiones del modelo de estrella.
4. Usuario final	Power BI Desktop & Service / REST APIs (FastAPI)	Permiten la exploración interactiva de tableros BI, visores geográficos y consulta de métricas por la SDM.
5. Gobierno, metadatos, monitoreo y seguridad	Apache Atlas / Great Expectations / AWS IAM	Gestionan el catálogo de metadatos, linaje del dato, reglas de calidad y seguridad de acceso por roles.

4.3 Marco de Referencia de cuatro categorías

Categoría	Decisión tomada	Justificación
Arquitectura de información	Modelo dimensional en constelación: Fact Siniestros y Fact Parque Automotor, con Dim Tiempo, Dim Hora, Dim Ubicación, Dim Tipo de siniestro, Dim Semáforo y Dim Vehículo.	Responde de forma directa y flexible a las preguntas de negocio P0-P3 agregando métricas por diversas perspectivas.

Categoría	Decisión tomada	Justificación
Arquitectura de datos	Pipeline ELT con capa de aislamiento (Raw S3 → Staging → DW PostgreSQL)	Garantiza trazabilidad, preserva los datos originales y permite transformaciones complejas de calidad.
Arquitectura técnica	Servicios Cloud PaaS / Managed Services (AWS Glue, S3, RDS PostgreSQL)	Proporciona alta disponibilidad, escalabilidad elástica y bajo mantenimiento de infraestructura.
Arquitectura de producto	Power BI Pro + Reportes incrustados en portal interno SDM	Facilita la adopción por parte de los decisores y analistas de movilidad mediante dashboards visuales.

4.4 Decisión de despliegue

Criterio	On-premise	Opción cloud: AWS	Elegida y por qué
Costo	Alto CAPEX inicial en servidores y almacenamiento físico.	OPEX escalable según demanda de procesamiento.	AWS Cloud PaaS: Elimina inversión inicial en hardware para la SDM.
Seguridad y cumplimiento	Control total interno pero alto costo de mantenimiento.	Cumplimiento de estándares internacionales ISO/IEC 27001.	AWS Cloud PaaS: Ofrece capas de cifrado nativo y respaldo continuo.
Escalabilidad	Limitada por la capacidad física instalada.	Escalabilidad elástica inmediata ante crecimiento de datos.	AWS Cloud PaaS: Soporta el volumen creciente de datos de movilidad.
Acceso móvil	Requiere VPNs complejas de configurar.	Acceso nativo seguro desde dispositivos móviles y web.	AWS Cloud PaaS: Facilita a los tomadores de decisión consultar KPIs en campo.

5. Modelo dimensional

▸ *Descripción del modelo elegido y la justificación*

5.1 Proceso de negocio

El proceso de negocio modelado corresponde a la Atención, Registro y Gestión de Siniestros Viales en la ciudad de Bogotá D.C. Este proceso captura cada evento de siniestro atendido por las autoridades de tránsito, registrando su severidad, ubicación y contexto de infraestructura semafórica, y se complementa con el parque automotor registrado en el RUNT, que se modela en una segunda tabla de hechos.

5.2 Granularidad

Una fila de la tabla de hechos representa un evento individual de siniestro vial registrado en una

ubicación geográfica (coordenadas X, Y y localidad) y en una fecha y hora específicas dentro del

Distrito Capital de Bogotá.

Una fila de la tabla de hechos de parque automotor representa los vehículos registrados en el RUNT que comparten la misma clase, carrocería, combustible y municipio de matrícula en un año de registro.

5.3 Métricas de la tabla de hechos

Métrica	Tipo de dato	Aditividad	Origen o fórmula
cantidad_siniestros	Entero	Aditiva	COUNT(CODIGO_ACCIDENTE) = 1 por fila
es_fatal (Muertos)	Entero (0/1)	Aditiva	CASE WHEN GRAVEDAD = 'CON MUERTOS' THEN 1 ELSE 0 END
es_con_heridos	Entero (0/1)	Aditiva	CASE WHEN GRAVEDAD = 'CON HERIDOS' THEN 1 ELSE 0 END
es_solo_danos	Entero (0/1)	Aditiva	CASE WHEN GRAVEDAD = 'SOLO DANOS' THEN 1 ELSE 0 END
indice_gravedad	Decimal	No aditiva	Fórmula ponderada: (3*es_fatal + 2*es_con_heridos + 1*es_solo_danos) / cantidad_siniestros
cantidad_vehiculos (Fact Parque Automotor)	Entero	Aditiva	SUM(CANTIDAD) del RUNT por año de registro

5.4 Dimensiones

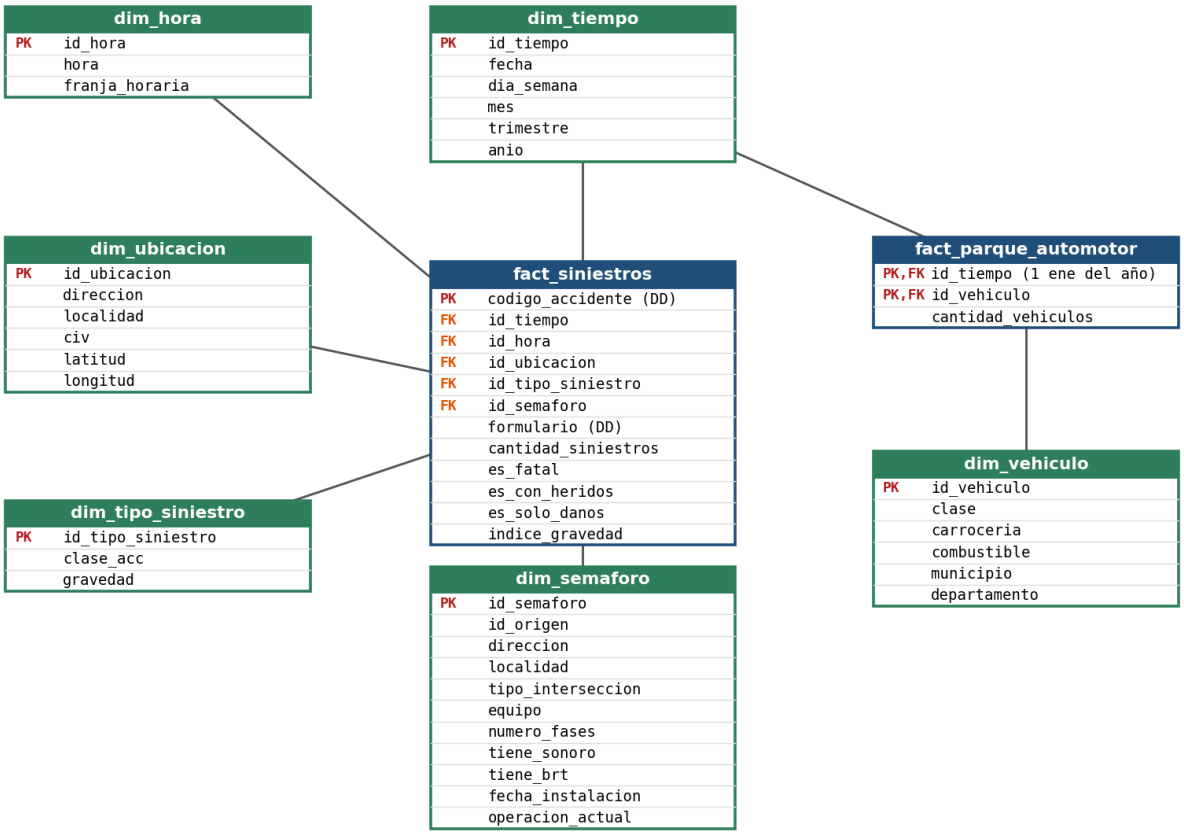
▸ *Mínimo cuatro, una de ellas de tiempo. Al menos dos con jerarquía.*

Dimensión	Atributos principales	Jerarquía	Fuente
Tiempo	fecha, día de la semana, mes, trimestre, año	día → mes → trimestre → año	Generada
Hora	hora, franja horaria	hora → franja horaria	Generada
Ubicación	dirección, localidad, CIV, latitud, longitud	localidad → dirección	F1 (Siniestros)
Tipo de siniestro	clase de siniestro, gravedad	—	F1 (Siniestros)

Dimensión	Atributos principales	Jerarquía	Fuente
Semáforo	id, dirección, localidad, tipo de intersección, equipo, número de fases, tiene sonoro, tiene BRT, fecha de instalación, operación actual	localidad → intersección	F2 (Red semafórica)
Vehículo	clase, carrocería, combustible, municipio, departamento	departamento → municipio	F3 (RUNT)

5.5 Diagrama del esquema

▸ *Muestre llaves primarias y llaves foráneas en la tabla de hechos. Subir el PNG y el archivo editable a /docs/diagramas. En este punto no se han creado tablas en base de datos, por lo tanto, no aplica el diagrama que se genera en la vista de DBeaver. En esta fase estamos en diseño*



PK = llave primaria · FK = llave foránea · DD = dimensión degenerada · Esquema en constelación (dos tablas de hechos con dim_tiempo compartida)

Se eligió un esquema en estrella extendido a constelación: dos tablas de hechos (siniestros y parque automotor) que comparten la dimensión Tiempo. Las dimensiones se mantienen desnormalizadas, sin tablas intermedias, porque son pequeñas (la de semáforos tiene 106 registros) y así las consultas necesitan menos uniones y el tablero en Power BI responde más rápido. Un copo de nieve no ahorraría espacio apreciable y complicaría el modelo. Los siniestros sin semáforo cercano se asignan a un miembro «Sin semáforo» de la dimensión Semáforo. El RUNT no

tiene llave común con los siniestros, por eso se modela como un hecho aparte que se cruza con ellos por año (drill-across) para responder P3.

5.6 Trazabilidad con las preguntas

▸ *Cada pregunta de la tabla 1.3 debe poder responderse con métricas y dimensiones que existen en el modelo.*

Pregunta	Métricas que usa	Dimensiones que usa
P0	cantidad_siniestros, es_fatal, es_con_heridos	Ubicación (localidad, dirección, CIV), Tiempo (año, mes)
P1	es_fatal, es_con_heridos, indice_gravedad, cantidad_siniestros	Semáforo (tipo de intersección, tiene BRT), Tipo de siniestro (gravedad)
P2	cantidad_siniestros	Hora (franja horaria), Tiempo (día de la semana), Tipo de siniestro (clase), Semáforo (tiene sonoro)
P3	cantidad_vehiculos (Fact Parque Automotor), cantidad_siniestros (Fact Siniestros)	Vehículo (combustible, clase, carrocería; filtro municipio = Bogotá), Tiempo (año, dimensión compartida entre ambos hechos)

6. Referencias

Alcaldía Mayor de Bogotá, & Secretaría Distrital de Movilidad. (2021). Diccionario de datos: Red semafórica de Bogotá D.C. Portal de Datos Abiertos de Bogotá. https://datosabiertos.bogota.gov.co/dataset/red-semaforica-sdm-bogota-d-c

Alcaldía Mayor de Bogotá, & Secretaría Distrital de Movilidad. (2021). Diccionario de datos: Siniestros viales en la ciudad de Bogotá D.C. Portal de Datos Abiertos de Bogotá. https://datosabiertos.bogota.gov.co/dataset/historico-siniestros-viales-bogota-d-c

DAMA International. (2017). DAMA-DMBOK: Data management body of knowledge (2nd ed.). Technics Publications.

Kimball, R., & Ross, M. (2013). The data warehouse toolkit: The definitive guide to dimensional modeling (3rd ed.). John Wiley & Sons.

Registro Único Nacional de Tránsito [RUNT]. (2021). Diccionario de datos: Vehículos eléctricos e híbridos registrados (2018–2020). Ministerio de Transporte de Colombia. https://www.runt.gov.co

Secretaría Distrital de Movilidad [SDM]. (2020). Base de datos histórica de siniestralidad vial en Bogotá D.C. (2018–2020) [Conjunto de datos]. Portal de Datos Abiertos de Bogotá. https://datosabiertos.bogota.gov.co/dataset/historico-siniestros-viales-bogota-d-c

Anexos

Anexo A. Diccionarios de datos

▸ *Un diccionario por fuente.*

Campo	Tipo	Descripción	Ejemplo	Problema de calidad

Anexo B. Diagramas a tamaño completo

▸ *Arquitectura y esquema dimensional, legibles a tamaño de página.*